

信号处理
Journal of Signal Processing
ISSN 1003-0530, CN 11-2406/TN

《信号处理》网络首发论文

题目：面向多用户大规模 MIMO 系统的信道估计研究
作者：安澄全，杨延，杨茜，李俊江
网络首发日期：2024-10-17
引用格式：安澄全，杨延，杨茜，李俊江. 面向多用户大规模 MIMO 系统的信道估计研究[J/OL]. 信号处理. <https://link.cnki.net/urlid/11.2406.TN.20241016.1829.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

面向多用户大规模 MIMO 系统的信道估计研究

安澄全^{*1} 杨延¹ 杨茜² 李俊江¹

(1. 哈尔滨工程大学信息与通信工程学院, 黑龙江哈尔滨 150001;

2. 航空工业第一飞机设计研究院, 陕西西安 710089)

摘要：获取大规模多输入多输出(Multiple-Input Multiple-Output, MIMO)系统的信道状态信息十分关键。频分双工(Frequency Division Duplexing, FDD)模式下, 传统的多用户信道估计问题是将多用户 MIMO 系统分解成多个单用户 MIMO 系统, 利用单用户的信道特性进行估计重构, 但随着基站端天线数量和用户数的增加, 不仅导频开销和重构算法的误差逐渐增大, 计算复杂度也随之上升, 导致系统整体性能下降。针对这一问题, 本文提出了一种基于压缩感知多测向量(Multiple Measurement Vector, MMV)模型的多用户联合信道估计方案: 利用多用户大规模 MIMO 系统中, 地理相邻用户角度域信道之间的共同稀疏性和独立稀疏性结构, 首先设计了适用于 MMV 模型的信道稀疏度估计策略, 通过排列稀疏分量的贡献率来获取信道稀疏度, 提高了稀疏先验信息未知或不准确条件下重构算法的性能。其次, 提出了一种分段残差动态反馈联合匹配追踪(Segmented Residual Dynamic Feedback joint Matching Pursuit, SRDFMP)算法, 通过区分不同属性的支撑集并分段估计, 有效降低了导频开销; 将所有用户的共同支撑集共享, 避免部分重复的迭代步骤; 针对不同支撑设置两种索引长度更新准则, 加快了算法的收敛速度; 同时本文算法也考虑了错误原子的纠正问题。仿真结果表明, 相比于传统算法, 本文所提算法具有更小的导频开销和优良的信道估计性能, 且在多用户条件下联合恢复的效率更高。

关键词：大规模多输入多输出; 信道估计; 压缩感知; 多测向量模型

中图分类号: TN929.5

文献标识码: A

Research on Channel Estimation for Multi-user Massive MIMO Systems

AN Chengquan^{*1} YANG Yan¹ YANG Qian² LI Junjiang¹

(1. School of Information and Communication Engineering, Harbin Engineering University,

Harbin, Heilongjiang 150001, China ;

2. AVIC First Aircraft Institute, Xi'an, Shaanxi 710089, China)

Abstract: It is critical to obtain the channel state information of massive Multiple-Input Multiple-Output (MIMO) systems. In Frequency Division Duplexing (FDD) mode, the traditional multi-user channel estimation problem is to decompose the multi-user MIMO system into multiple single-user MIMO systems, and use the channel characteristics of the single user for estimation and reconstruction. However, with the increase of the number of antennas at the base station and the number of users, not only the pilot overhead and the error of the reconstruction algorithm increase gradually, but also the computational complexity increases, resulting in the overall system performance decline. To address this problem, this paper proposes a multi-user joint channel estimation scheme based on the compressed sensing Multiple Measurement Vector (MMV) model: Based on the common sparsity and independent sparsity structure among the channels in the Angle

*通讯作者: 安澄全 anchengquan@hrbeu.edu.cn

*Corresponding Author: AN Chengquan, anchengquan@hrbeu.edu.cn

基金项目: 黑龙江省重点研发计划(2023ZX01A20)

Foundation Items: The Key R&D Program of Heilongjiang (2023ZX01A20)

domain of geographically adjacent users in the multi-user massive MIMO system, a channel sparsity estimation strategy suitable for MMV model is first designed. The channel sparsity estimation strategy is obtained by ranking the contribution rate of sparse components, which improves the performance of the reconstruction algorithm under the condition of unknown or inaccurate sparse prior information. Secondly, a Segmented Residual Dynamic Feedback joint Matching Pursuit (SRDFMP) algorithm is proposed. The algorithm uses several innovative techniques: By differentiating support sets with different attributes and estimating them in segments, effectively reducing the pilot frequency overhead; By sharing the common support sets of all users to avoid some redundant iteration steps; Two index length updating criteria are set according to different supports to accelerate the convergence speed of the algorithm. At the same time, the problem of correcting the wrong atoms is also considered. Simulation results show that compared with traditional algorithms, the proposed algorithm has lower pilot cost, better channel estimation performance, and higher joint recovery efficiency under multi-user conditions.

Key words: massive multiple input multiple output; channel estimation; compressed sensing; multiple measurement vector model

1 引言

大规模 MIMO 系统由于其在容量和可靠性方面的性能提升,被视为第五代和下一代无线通信系统的关键技术^[1]。为了实现大规模 MIMO 系统的空间复用和阵列性能增益,必须在基站(Base Station, BS)上获取下行信道状态信息(Channel State Information, CSI)^[2-3],在 FDD 模式下,上行信道和下行信道的不存在互易性,因此用户必须先行估计下行信道的 CSI,然后反馈给 BS 端^[4]。然而在 FDD 大规模 MIMO 系统中,常规的信道估计方法所需的导频开销巨大,如最小二乘(Least Squares, LS)或最小均方误差(Minimum Mean Square Error, MMSE)算法^[5],所需导频数量总是随 BS 端天线数量呈线性增长趋势。

由于天线周围的局部散射体的限制,信道矩阵随着天线数量的增加而趋于稀疏^[6]。而压缩感知(CS)可以在原始信号稀疏的情况下,利用少量的测量值以较高概率恢复出原始信号^[7],因此一些压缩感知经典算法已被广泛应用于大规模 MIMO 系统的信道估计中,以便在导频长度较小的情况下恢复出稀疏信道的 CSI^[8]。文献[9]针对 FDD 模式下用户端移动所导致的时变特性,提出了一种自适应结构化正交匹配追踪(Adaptive Structured Orthogonal Matching Pursuit, AS-JOMP)算法,利用无线 MIMO 信道的结构化稀疏性自适应的重构稀疏信道,并对信道恢复值进行深度学习网络去噪处理,该算法不需要时变信道的稀疏性先验信息,且导频开销相对较少。文献[10]提出了一种联合相关稀疏匹配追踪(Joint Correlation Sparsity Matching Pursuit, JCSMP)算法,用于恢复无线信道的 CSI,该算法具有较高的支撑集搜索效率和较低的计算复杂度,且在稀疏自适应性方面更加稳健。文献[11]建立了大规模 MIMO 系统的角频域和角延迟域的概率信道模型,并提出两种基于结构化 Turbo 压缩感知的信道估计算法,仿真表明其算法具有较快的收敛速度和较小的均方误差。上述信道估计方法将压缩感知应用于单个点对点链路,即仅考虑 BS 端与一个用户之间,在面对多个用户联合信道估计的问题时,由于未考虑地理相邻用户信道矩阵间的联合稀疏性,所以性能发挥有限。

在大规模 MIMO 系统中,多用户信道矩阵可以观察到其共享相同的局部散射体,这一特性在许多实验研究中得到了验证,同时也为压缩感知应用于非点对点的多用户链路,并进行信道联合恢复的问题提供了解决思路。文献[12]利用毫米波 MIMO 信道在多用户傅里叶域的联合块稀疏结构,提出了一种广义块正交匹配追踪(Generalized Block Orthogonal Matching Pursuit, G-BOMP)算法,适用于单独估计每个用户的信道和联合估计所有用户的信道,并推导了算法的重构误差。文献[13]总结了多用户大规模 MIMO 系统角域信道的稀疏特征,利用多个用户信道之间隐藏的稀疏性,提出了一种基于分布式压缩感知理论的信道重构算法,使得一组稀疏信道矩阵在 BS 端能被联合测量和恢复,仿真结果表明其方案相比常规单链路的信道估计具有实质的性能提升。文献[14]通过矩阵变换提取了多用户信道矩阵的块稀疏性,提出一种联合块正交

匹配追踪(Joint Block Orthogonal Matching Pursuit, JBOMP)多链路信道重构算法。文献[15]利用多用户信道的块稀疏特性和相关先验知识,提出了一种两阶段加权块最小化 ℓ_1 的压缩感知算法,用于联合恢复多用户信道,并讨论了加权系数对用户CSI估计质量的影响,仿真结果表明该算法的估计精度要高于传统的贪婪算法。上述算法需要较为精确的稀疏度先验信息,而且重构算法的原子筛选方式较为固定,导致多用户联合信道估计时算法的运算效率不高;另一方面,在迭代求解的过程中,针对传感矩阵的列自相关系数而引起的错误支撑没有很好的纠正,导致了算法重构精度存在优化空间。

关于预估稀疏度信息的问题,文献[16]将观测向量重新组合为矩阵,并给出重组矩阵的秩与未知信号稀疏度阶一致的条件,以此来推测稀疏度,但该方法对测量矩阵具有严格的结构约束。文献[17]提出一种鲁棒稀疏度估计方法,该方法利用贪婪算法和相对阈值对稀疏度进行估计,仿真表明其在低信噪比场景或信号变化时具有较好的性能。文献[18]通过分析观测信号能量与压缩率、稀疏度和信噪比之间的对应关系,提出一种基于观测信号能量的稀疏度估计算法,仿真表明了其具有更好的估计精度,但该算法在估计之前需构造稀疏率与能量关系对照表,增加了整体复杂性。文献[19]通过利用稀疏度过估计和欠估计的判据,提出一种基于有限等距性质(Restricted Isometry Property, RIP)的稀疏度预测算法,在稀疏度未知的情况下,能快速逼近真实稀疏度,但该算法的估计精度有待进一步提高。

本文在多用户信道联合稀疏特征的基础上,首先设计了MMV模型下的信道稀疏度预估计策略,用于提供准确的信道稀疏先验信息,接着提出了一种分段残差动态反馈联合匹配追踪(Segmented Residual Dynamic Feedback joint Matching Pursuit, SRDFMP)算法用于恢复信道CSI,为降低导频开销,算法针对共同和独立两个属性的支撑集分阶段求解,并将估计过程中多用户间的共同支撑集共享,减少重复计算次数;同时设计了两种索引长度更新准则,以提高迭代中算法的收敛速度;此外采用匹配本文信道结构的动态回溯机制,纠正迭代中的错误支撑,提高重构算法的恢复精度。仿真结果表明,本文算法有着更小的导频开销和估计误差,且运算效率更高。

2 系统模型

2.1 多用户大规模MIMO系统

考虑FDD工作模式下的多用户大规模MIMO系统,由一个BS和 U 个用户组成,BS配置 M 根天线,每个用户配置 N 根天线。通过块衰落信道考虑基站与每个用户之间的信息传输,在相干时间内假定信道保持静态。信号帧由导频序列和数据信号组成,由BS在其 M 根天线上传输,第 j 个时隙的发射导频记为 $\mathbf{x}_j \in \mathbb{C}^{M \times 1}, j=1, \dots, T$,其中 T 为总时隙。则在第 j 个时隙,得到第 i 个用户的接收信号矢量:

$$\mathbf{y}_{ij} = \mathbf{H}_i \mathbf{x}_j + \mathbf{n}_{ij}, j=1, \dots, T \quad (1)$$

其中 $\mathbf{H}_i \in \mathbb{C}^{N \times M}$ 和 $\mathbf{n}_{ij} \in \mathbb{C}^{N \times 1}$ 分别表示第 i 个用户的信道矩阵和信道加性高斯白噪声。考虑所有时隙,将式(1)重新写为:

$$\mathbf{Y}_i = \mathbf{H}_i \mathbf{X} + \mathbf{N}_i, 1 \leq i \leq U \quad (2)$$

其中 $\mathbf{Y}_i = [\mathbf{y}_{i1}, \mathbf{y}_{i2}, \dots, \mathbf{y}_{iT}] \in \mathbb{C}^{N \times T}$ 表示第 i 个用户在所有时隙的接收信号矩阵, $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T] \in \mathbb{C}^{M \times T}$ 表示所有时隙的发射导频序列, $\mathbf{N}_i = [\mathbf{n}_{i1}, \mathbf{n}_{i2}, \dots, \mathbf{n}_{iT}] \in \mathbb{C}^{N \times T}$ 表示各时隙第 i 个用户处的噪声矩阵。为了将信道估计问题转化为稀疏信号重构问题,在角度域表示信道矩阵 $\mathbf{H}_i$:

$$\mathbf{H}_i = \boldsymbol{\Theta}_R \mathbf{H}_i^a \boldsymbol{\Theta}_T^H \quad (3)$$

其中 $\boldsymbol{\Theta}_T$ 和 $\boldsymbol{\Theta}_R$ 分别是发送和接收侧的角度域变换酉矩阵, $\mathbf{H}_i^a \in \mathbb{C}^{N \times M}$ 是角度域的信道矩阵,第 n 行用 $\mathbf{h}_n$ 表示:

$$\mathbf{h}_n = [\mathbf{h}_n(1), \mathbf{h}_n(2), \dots, \mathbf{h}_n(M)], 1 \leq i \leq U, 1 \leq n \leq N \quad (4)$$

2.2 联合稀疏特性

从文献[6][13]的工作可知，多用户大规模 MIMO 系统中的无线传播环境只存在有限数量的有效散射体，每个用户的角度域信道矩阵趋于稀疏，而且不同用户的信道矩阵之间还存在一种隐藏的稀疏结构，如图 1 所示。




图 1 多用户联合稀疏角度域信道模型

Fig. 1 Multi-user joint sparse angle domain channel model

(1) 基站侧具有较高的相对高度，导致其周围的散射体数量较少，而用户通常被较多的局部散射体包围。因此单用户的角度域信道矩阵 $\mathbf{H}_i^a$ 的每个行向量具有相同的稀疏支持：

$$\mathbf{D}_{i1} = \mathbf{D}_{i2} = \cdots = \mathbf{D}_{iN} = \Lambda_i \quad (5)$$

其中 $\mathbf{D}_{in} = \text{supp}(\mathbf{h}_{in})$ 为 $\mathbf{h}_{in}$ 非零项的索引集合， Λ_i 表示第 i 个用户非零项索引集。

(2) 当用户在地理位置上距离接近时，不同用户倾向于在 BS 处共享一些共同的局部散射体，因此这些信道矩阵间可能具有部分共同的支持。对于所有 U 个用户，存在一个公共的非零支撑集：

$$\bigcap_{i=1}^U \Lambda_i = \Lambda_c \quad (6)$$

其中 Λ_c 表示所有 U 个用户角度域信道矩阵非零项的共同支撑索引集。因此，多用户信道的稀疏特性可以表示为 $\Lambda = \{\Lambda_c, \{\Lambda_i : \forall i, 1 \leq i \leq U\}\}$ 。若假设共同稀疏度下限 $\|\Lambda_c\|_0 \geq c$ ，用户 i 的信道稀疏度为 K_i ，则上述特性可用统计模型简化为 $\Gamma = \{c, \{K_i : \forall i\}\}$ 。

实际中，统计信道模型依赖于散射环境的大尺度特性，在一定时隙内保持不变。因此，基于传播环境的先验知识，对于多用户信道的统计共同稀疏下限 c ，可以在 BS 端的离线信道传播测量，或从长期的随机学习估计中获得^[13]，用户的信道稀疏度信息 K_i 由后续提出的稀疏度估计算法来获得。

2.3 压缩感知模型

为利用上节的联合稀疏特性，并通过压缩感知模型求解信道估计问题，将式(2)重新表述为：

$$\mathbf{Y}_i' = \mathbf{H}_i^a \mathbf{X}' + \mathbf{N}_i', 1 \leq i \leq U \quad (7)$$

其中 $\mathbf{Y}_i' = \mathbf{\Theta}_R^H \mathbf{Y}_i \in \mathbb{C}^{N \times T}$ ， $\mathbf{X}' = \mathbf{\Theta}_T^H \mathbf{X} \in \mathbb{C}^{M \times T}$ ， $\mathbf{N}_i' = \mathbf{\Theta}_R^H \mathbf{N}_i \in \mathbb{C}^{N \times T}$ ，上式并非标准的压缩感知模型，通过共轭转置运算，将式(7)转化为：

$$\bar{\mathbf{Y}}_i = \bar{\mathbf{X}} \bar{\mathbf{H}}_i + \bar{\mathbf{N}}_i, 1 \leq i \leq U \quad (8)$$

其中 $\bar{\mathbf{Y}}_i = \mathbf{Y}_i^H \mathbf{\Theta}_R \in \mathbb{C}^{T \times N}$ ， $\bar{\mathbf{X}} = \mathbf{X}^H \mathbf{\Theta}_T \in \mathbb{C}^{T \times M}$ ， $\bar{\mathbf{H}}_i = (\mathbf{H}_i^a)^H \in \mathbb{C}^{M \times N}$ 和 $\bar{\mathbf{N}}_i = \mathbf{N}_i^H \mathbf{\Theta}_R \in \mathbb{C}^{T \times N}$ 。不难发现，式(8)为标准的压缩感知多测量向量模型，其中角域导频矩阵 $\bar{\mathbf{X}}$ 对应传感矩阵，信道矩阵 $\bar{\mathbf{H}}_i$ 对应待重构的稀疏信号，其行元素要么全为零，要么全为非零。

BS 端和用户之间的信道估计过程如下。采用共享导频策略，BS 端首先向所有 U 个用户广播满足 $T \ll M$ 的导频序列 $\mathbf{X} \in \mathbb{C}^{M \times T}$ 。接着，用户 i 得到测量值 $\mathbf{Y}_i$ 并且将其反馈至 BS 端。BS 得到所有 U 个用户的信道测量值 $[\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_U]$ ，对其进行联合处理，最后得到信道估计矩阵 $[\mathbf{H}_1^e, \mathbf{H}_2^e, \dots, \mathbf{H}_U^e]$ 。其中 BS 端的估计问题为：

$$\bar{\mathbf{H}}_i^e = \min_{\{\bar{\mathbf{H}}_i\}} \sum_{i=1}^U \|\bar{\mathbf{Y}}_i - \bar{\mathbf{X}}\bar{\mathbf{H}}_i\|_F^2, 1 \leq i \leq U \quad (9)$$

为了提高信道重构算法的精度和加快算法的收敛速度，下一节将首先提出基于 MMV 模型的稀疏度预估计策略，计算出信道矩阵的稀疏度，并将其作为重构算法的输入。

3 基于 MMV 模型的信道估计算法

3.1 稀疏度估计策略

针对式(8)对应压缩感知 MMV 模型的稀疏度估计问题，目前主流研究利用基于 RIP 的稀疏估计判据来对信号稀疏度进行迭代逼近^[19-20]。本文受到主成分分析(Principal Component Analysis, PCA)处理多维样本，对其进行数据降维和压缩^[21]的启发，主成分变换类似与压缩感知，变换后的测量值保留了原始信号的大部分信息，其原理是将原始数据进行线性变换，使数据任何投影的第一方差在第一坐标，第二方差在第二坐标，依次类推，可表示为：

$$\mathbf{Y} = \mathbf{Q}\mathbf{X} \quad (10)$$

其中 $\mathbf{X}$ 为原始数据， $\mathbf{Y}$ 为变换后数据， $\mathbf{Q}$ 为正交变换矩阵。若原始数据矩阵 $\mathbf{X}$ 为：

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix} \quad (11)$$

矩阵 $\mathbf{X}$ 的奇异值分解为 $\mathbf{X} = \mathbf{W}\mathbf{\Sigma}\mathbf{V}^H$ ，其中矩阵 $\mathbf{W}$ 和矩阵 $\mathbf{V}$ 分别为 m 阶和 n 阶酉矩阵， $\mathbf{\Sigma}$ 为 $m \times n$ 阶非负矩形对角矩阵。同时通过 $\mathbf{W}^H$ 观测数据矩阵 $\mathbf{X}$ ，可得：

$$\mathbf{P} = \mathbf{W}^H \mathbf{X} = \mathbf{W}^H \mathbf{W} \mathbf{\Sigma} \mathbf{V}^H = \mathbf{\Sigma} \mathbf{V}^H \quad (12)$$

其中 $\mathbf{P}$ 为观测值， $\mathbf{P}^H$ 的第一列为第一主成分，第二列为第二主成分，依次类推，并且观测值协方差矩阵主对角线上的元素反映了其能量分布情况。

考虑按贡献度排列 BS 端获得测量值的所有主成分分量，每个主成分都对应一个特征值，则其中存在 K 个贡献度排列较大的分量，这些分量对应稀疏信道矩阵的非零项。然后将所求分量的主成分系数作差分计算，进一步得出稀疏度与主成分分量之间更为精确的关系，最后选取贡献率满足阈值的分量并统计数目，具体算法流程如表 1 所示。

表 1 差分阈值 PCA 分析的稀疏度估计

Tab. 1 Sparsity estimation of difference threshold PCA analysis

算法流程
输入： 用户 i 的信道测量值 (1) 计算观测矩阵的标准化协方差矩阵 (2) 计算协方差矩阵的特征值 λ_t ，其中 $t=1, 2, \dots, n$ (3) 将特征值按升序排列 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ ，并做一阶差分处理 (4) 求差分首次满足 $\Delta Z_n \geq \eta, (\eta < 1)$ 的贡献度跳变阈值点，返回索引值 n (5) 统计跳变值下标 n 排列右侧的主成分分量数目 P_n 输出： 用户 i 的信道稀疏度估计值 $\hat{K}_i = P_n$

3.2 分段残差动态反馈联合匹配追踪算法

不同于单用户信道估计，本文的多用户联合稀疏信道估计建立在 MMV 模型下进行，由于其信道支撑集具有共同和独立属性，因此本节的算法通过分段识别和估计来进行，引入了共同残差门限值概念作为索引长度更新函数的参数，保证了残差的递减趋势，并能针对不同支撑集动态且精确的调整索引长度，加快

迭代速度。同时，在两阶段估计的过程中使用了不同的回溯策略对误判原子进行了纠正，以提高重构精度，具体算法流程如表 2 所示。

表 2 分段残差动态反馈联合匹配追踪算法

Tab. 2 Segmented Residual Dynamic Feedback joint Matching Pursuit algorithm

算法流程
输入: 测量值 $\{\bar{Y}_i, \forall i\}$, 导频矩阵 $\bar{X}$, 用户信道稀疏度估计值 $\{\hat{K}_i, \forall i\}$, 共同稀疏度 c 阶段 1 初始化: 初始残差 $\mathbf{r}_i = \bar{Y}_i$, 索引长度 $S_i = c$, 候选集 $\Lambda_i = \emptyset$, 共同支撑集 $\Lambda_c = \emptyset$, 门限值 $T_i^c = 0$, 迭代次数 $t = 1$ (1) 计算出用户 i 最优的长度为 S_i 的支撑集: $\Lambda_i = \operatorname{argmax}_l (\ (\bar{X}_l)^H \mathbf{r}_i\ _{\text{row-1}}, S_i)$ (2) 根据式(13), 筛选出对所有 U 个或最多数量的求解模型同时存在贡献的支撑集: $\Lambda_c = \Lambda_{\alpha} \cup \Lambda_c$ (3) 计算投影估计值: $\hat{\mathbf{h}}_i = (\bar{X}_{\Lambda_c}^T \bar{X}_{\Lambda_c})^{-1} \bar{X}_{\Lambda_c}^T \bar{Y}_i$; 根据式(14)进行固定值回溯, 剔除掉 $\hat{\mathbf{h}}_i$ 中的误估元素, 同时更新 Λ_c 和 $\hat{\mathbf{h}}_i$ (4) 更新残差: $\mathbf{r}_i = \bar{Y}_i - \bar{X}_{\Lambda_c} \hat{\mathbf{h}}_i$ (5) 停止条件: if $\ \Lambda_c\ _0 = c$ 且 $\ \mathbf{r}_i\ _F - \ \mathbf{r}_{i-1}\ _F > 0$; 停止迭代, 输出共同支撑集 Λ_c 以及共同残差门限值 $T_i^c = \ \mathbf{r}_i\ _F$。否则转至步骤(1), $t = t + 1$ 阶段 2 初始化: 初始残差 $\mathbf{R}_n = \mathbf{r}_i$, 索引长度初值 $S_i = c$, 候选集 $\Lambda_n = \emptyset$, 迭代次数 $n = 1$ (6) 添加阈值 T_i^c 下对用户 i 信道恢复贡献最优的长度为 S_i 的支撑集: $\Lambda_n = \Lambda_c \cup \operatorname{argmax}_l (\ (\bar{X}_l)^H \mathbf{R}_n\ _{\text{row-1}}, S_i)$ (7) 计算暂态解: $\hat{\mathbf{H}}_n = (\bar{X}_{\Lambda_n}^T \bar{X}_{\Lambda_n})^{-1} \bar{X}_{\Lambda_n}^T \bar{Y}_i$; 根据式(14)进行动态值回溯, 同时更新 Λ_n 和 $\hat{\mathbf{H}}_n$ (8) 更新残差 $\mathbf{R}_n = \bar{Y}_i - \bar{X}_{\Lambda_n} \hat{\mathbf{H}}_n$, 根据式(16)更新索引长度 S_i (9) 停止条件: if $\ \mathbf{R}_n\ _F < 1e^{-6}$ 或 $n > \hat{K}_i - c$; 停止迭代。否则转至步骤(6), $n = n + 1$ 输出: 用户 i 的信道矩阵的重构值 $\hat{\mathbf{H}}_n$

算法分为共同支撑估计和独立支撑估计两个阶段进行, 将 BS 接收到的用户 i 测量值 $\bar{Y}_i$, 信道共同稀疏度下限 c , 信道矩阵稀疏度估计值 $\hat{K}_i$ 作为输入条件。阶段 1 初始化后, 首先将残差 $\mathbf{r}_i$ 投影到传感矩阵 $\bar{X}$ 上, 找出与当前残差最相关的 S_i 个字典矩阵 $\bar{X}$ 的原子索引, 其集合为 Λ_i , 其中本阶段的索引长度取值 S_i 固定为 c 不变。在 Λ_i 的基础上, 还需求解问题式(13): 筛选出对所有 U 个或最多用户方向同时存在贡献的支撑集, 其中 $I_A(\cdot)$ 表示指示函数, 这限定了阶段 1 的计算仅针对多用户的共同支撑。

$$\Lambda_{\alpha} = \bigcup \operatorname{argmax}_{l \in \Lambda_i} \sum_{1 \leq j \leq U} I_A(l \in \operatorname{argmax}_L (\|(\bar{X}_L)^H \bar{Y}_j\|_{\text{row-1}}, \hat{K}_j)) \quad (13)$$

计算出初步的投影估计值后, 需采用式(14)所示的固定值回溯机制 ($g = c$), 纠正 $\hat{\mathbf{h}}_i$ 中的误估元素, 提高共同支撑集的准确率, 并将阶段 1 迭代过程中 $\|\Lambda_c\|_0$ 的上限始终保持为共同稀疏度限 c 。然后更新残差 $\mathbf{r}_i$, 在集合 Λ_c 未饱和之前残差能量会呈递减趋势, 若残差能量开始递增, 则说明出现新的用户独立分量加入计算。因此, 设置残差非递减和共同稀疏度限须同时满足, 为达到阶段 1 停止条件, 输出多用户共同支撑集 Λ_c 和用户 i 的共同残差门限 T_i^c , 将其作为阶段 2 的迭代输入。

$$\hat{\mathbf{h}}_{i-\text{new}} = \max(\|\hat{\mathbf{h}}_i\|_{\text{row-1}}, g) \quad (14)$$

阶段 2 为独立支撑集估计。初始化后, 将剩余残差 $\mathbf{R}_n$ 投影到字典矩阵 $\bar{X}$ 上, 求解与用户剩余残差最相关的 S_i 个传感矩阵 $\bar{X}$ 的原子集合, 其中阶段 2 的索引长度 S_i 根据门限 T_i^c 作动态更新, 稍后说明, 索引集合 Λ_n 是在共同支撑的基础上不断添加新的独立支撑集。计算出暂态解 $\hat{\mathbf{H}}_n$ 后, 回溯机制与式(14)不同之处在于参数 $g (c < g \leq \hat{K}_i)$ 根据式(15)动态更新, 以增加阶段 2 中误估元素的纠正次数, 避免 $\|\Lambda_n\|_0 < \hat{K}_i$ 时不进行回溯的情况, 提高独立支撑集的准确率, 接着同步更新残差与索引长度。为保证计算精度和避免重复迭代, 达到残差收敛值或最大独立支撑迭代次数算法停止, 并输出信道估计值。

$$g = \min(c + nS_i, \hat{K}_i) \quad (15)$$

针对索引长度的更新准则, 阶段 1 只针对多用户的共同支撑, 故设置固定长度值 $S_i = c$, 结合特定步

骤(2), 可优先求解出占比为 $c/\hat{K}_i$ 的公共分量。实验发现在阶段 2, 残差呈非线性递减的变化趋势, 继续固定长度会使算法分辨率变低, 导致计算次数增多并降低重构精度, 因此采用式(16)较精确的控制索引长度值动态更新, 其中惩罚项使其与独立残差作正相关变化, 直至迭代停止。

$$S_i = \lceil \|\mathbf{R}_n\|_F / T_i^c \rceil c \quad (16)$$

3.3 克拉美-罗下界分析

克拉美-罗下界(Cramér-Rao Lower Bound, CRLB)是衡量估计结果无偏性的指标^[22], 本节通过推导 CRLB 来证实所提出信道估计算法的有效性。首先根据 CRLB 的定义, 复信道参数每一个元素的 CRLB 可通过费歇尔信息矩阵(Fisher Information Matrix, FIM)逆的矩阵迹求得:

$$\text{CRLB}(\bar{\mathbf{H}}_\Lambda) = \text{trace}[\mathbf{J}^{-1}(\bar{\mathbf{H}}_\Lambda)] \quad (17)$$

其中 $\mathbf{J}(\cdot)$ 为费歇尔信息矩阵。由式(8), 噪声信号服从均值为 0, 方差为 σ^2 的复高斯分布, 即 $\mathbf{N} \sim \mathcal{CN}(0, \sigma^2 \mathbf{I}_N)$, 因此基站端接收信号同样服从复高斯分布, 且对任意用户有 $\bar{\mathbf{Y}} \sim \mathcal{CN}(\bar{\mathbf{X}}_\Lambda \bar{\mathbf{H}}_\Lambda, \sigma^2 \mathbf{I}_N)$, 所以在给定条件下, 接收信号的概率密度函数(Probability Density Function, PDF)为:

$$p(\bar{\mathbf{Y}}; \bar{\mathbf{H}}_\Lambda) = \frac{1}{(\pi\sigma^2)^\mu} \exp\left(-\frac{1}{\sigma^2} (\bar{\mathbf{Y}} - \bar{\mathbf{X}}_\Lambda \bar{\mathbf{H}}_\Lambda)^H (\bar{\mathbf{Y}} - \bar{\mathbf{X}}_\Lambda \bar{\mathbf{H}}_\Lambda)\right) \quad (18)$$

其对数概率密度函数为:

$$\ln p(\bar{\mathbf{Y}}; \bar{\mathbf{H}}_\Lambda) = -\mu \ln(\pi\sigma^2) - \frac{1}{\sigma^2} (\bar{\mathbf{Y}} - \bar{\mathbf{X}}_\Lambda \bar{\mathbf{H}}_\Lambda)^H (\bar{\mathbf{Y}} - \bar{\mathbf{X}}_\Lambda \bar{\mathbf{H}}_\Lambda) \quad (19)$$

费歇尔信息矩阵的第 (i, j) 个元素可以表示为:

$$[\mathbf{J}(\bar{\mathbf{H}}_\Lambda)]_{i,j} = \mathbb{E} \left[-\frac{\partial^2 \ln p(\bar{\mathbf{Y}}; \bar{\mathbf{H}}_\Lambda)}{\partial \bar{\mathbf{H}}_{\Lambda,i} \partial \bar{\mathbf{H}}_{\Lambda,j}} \right] \quad (20)$$

将式(19)代入式(20), 可得:

$$\mathbf{J}(\bar{\mathbf{H}}_\Lambda) = \frac{1}{\sigma^2} \bar{\mathbf{X}}_\Lambda^H \bar{\mathbf{X}}_\Lambda \quad (21)$$

结合式(17)(21), 本文算法的 CRLB 由下式给出:

$$\text{CRLB}(\bar{\mathbf{H}}_\Lambda) = \sigma^2 \text{trace}[(\bar{\mathbf{X}}_\Lambda^H \bar{\mathbf{X}}_\Lambda)^{-1}] \leq \mathbb{E} \left[\|\mathbf{H}_i - \hat{\mathbf{H}}_i\|^2 \right] \quad (22)$$

3.4 复杂度分析

利用 U 个用户联合信道估计过程中, 复乘运算的总次数来评价本文方案的计算复杂度, 稀疏度估计策略进行复乘运算次数约为 $(MN + T^2)TU$, 若在共同支撑估计阶段进行了 t 次迭代, 则复乘运算次数约为 $c^3(2t + U) + 2c^2T(2t + U) + cTN(3t + 2U) + MNT(t + U)$, 在独立支撑估计阶段进行了 n 次迭代, 那么复乘运算次数约为 $2K_i^3Un + 4K_i^2TUn + TNUn(M + 3K_i)$, 本文算法针对不同支撑动态的调整索引长度, 使得通常情况下迭代次数 t 和 n 很难接近运算次数的上限, 且均远小于 K_i , 因此计算复杂度可近似为 $O((K_i^3 + c^3 + T^3)U + (K_i^2 + c^2)TU + (M + K_i + c)NTU)$ 。在相同条件下, 若采用文献[10]算法联合估计 U 个用户的信道, 计算复杂度可近似为 $O((K_i^2 + K_iM)NTU)$; 采用文献[13]算法的计算复杂度可近似为 $O((K_i^3p + c^4)U + (K_i^2p + c^3)TU + (K_i^2 + K_iM)NTU)$, 其中 $p = K_i - c$; MMV 模型下其余三种算法的计算复杂度如表 3 所示。由表可知, 本文算法在多用户联合信道估计时的计算复杂度更小, 收敛速度更快。

表 3 不同算法的复杂度对比

Tab. 3 Complexity comparison of different algorithms

本文算法	$O((K_i^3 + c^3 + T^3)U + (K_i^2 + c^2)TU + (M + K_i + c)NTU)$
文献[10]算法	$O((K_i^2 + K_i M)NTU)$
文献[13]算法	$O((K_i^3 p + c^4)U + (K_i^2 p + c^3)TU + (K_i^2 + K_i M)NTU)$
MMV-CoSaMP 算法	$O(K_i^4 U + K_i^3 TU + (K_i^2 + K_i M)NTU)$
MMV-gOMP 算法	$O(K_i^4 U + K_i^3 TU + (K_i^2 + K_i M)NTU)$
MMV-SAMP 算法	$O(K_i^4 U + K_i^3 TU + (K_i^2 + K_i M)NTU)$

4 仿真分析

本节通过仿真来评估本文所提的多用户联合信道估计算法与现有算法性能的对比，主要分析在不同条件下，算法的归一化均方误差(Normalized Mean Square Error, NMSE)变化情况，定义为式(23)，以及多用户联合估计时的运行效率。考虑一个窄带多用户 FDD 大规模 MIMO 系统，其中 BS 端天线数目设置为 $M = 128$ ，用户端天线数目设置为 $N = 4$ ，同时采用经典的 QuaDRiGa 模型^[23]来生成信道系数，各用户信道具有前节所述的联合稀疏结构，设定比值 $K_r/M, c/M$ 与文献[13]相同，故角度域信道的真实稀疏度取 $K_r = 21$ ，多用户的共同稀疏支撑集下界固定为 $c = 8$ 。

$$\text{NMSE} = \frac{1}{R} \sum_{r=1}^R \frac{\|\mathbf{H}_i - \hat{\mathbf{H}}_i\|_F^2}{\|\mathbf{H}_i\|_F^2} \quad (23)$$

其中 R 为样本数量， $\mathbf{H}_i$ 为信道真实值， $\hat{\mathbf{H}}_i$ 为信道估计值。

图 2 给出了在角度域信道真实稀疏度 $K_r = 21$ 时，不同 SNR 下本文提出的稀疏度估计策略与文献[17]、文献[18]算法，以及文献[19]中基于 RIP 的稀疏度预测方法得出的结果对比。为规避偶然因素，稀疏度的估计输出设置为运行 1000 次后的平均值取整。由图可知，本文的估计策略性能优于其他三种方法，当 $\text{SNR} \geq 10$ dB 时，估计值趋于稳定且与真实值的误差达到最小，因此可以为本文后续的信道重构算法提供可靠的稀疏度信息。




图 2 不同信噪比和算法下稀疏度估计对比

Fig. 2 Comparison of sparsity estimation under different signal-to-noise ratios and algorithms

图 3 给出了在固定导频开销 $T = 60$ ，用户数目 $U = 20$ 时，不同 SNR 下本文算法与文献[10]、文献[13]算法，以及 CoSaMP、gOMP、SAMP 算法估计得到信道信息的 NMSE。随着 SNR 的增加，信道环境逐渐

提升, 各算法的信道估计性能和估计准确度也在不断增加, 本文算法相比其他五种算法有实质性的性能增益, 并且能更好的逼近 CRLB 限。本文算法利用多用户信道矩阵间隐藏的共同稀疏先验信息, 确保在任一用户得出的支撑集中, 至少有 c 个对所有用户方向存在贡献的支撑是被正确估计的, 而动态回溯机制分别将两阶段估计值中系数较小的误估元素剔除, 降低原子选取的错误率, 二者整体提升了信道重构的概率, 同时较为精确的稀疏度预测保证了其在信噪比变化过程中均有良好的系统性能, 由此验证了算法可行性。




图3 不同信噪比和算法下的 NMSE

Fig. 3 NMSE under different signal-to-noise ratios and algorithms

图 4 给出了在固定 $\text{SNR} = 20 \text{ dB}$, 用户数目 $U = 20$ 时, 不同导频开销下本文算法与文献[10]、文献[13]算法, 以及 CoSaMP、gOMP、SAMP 算法估计得到信道信息的 NMSE。因为导频长度关乎迭代求解中索引矩阵的列相关度, 接近取值下限会增大选取错误原子的概率, 进而导致恢复率降低。本文算法分段的选取策略降低了迭代过程中传感矩阵列相关约束的下限, 同时也是降低导频开销的关键, 这使其在训练序列长度较小时估计性能均优于其他算法, 并随着导频长度变化保持稳定, 因此本文算法在导频开销方面具有明显优势。




图4 不同开销和算法下的 NMSE

Fig. 4 NMSE under different overheads and algorithms

图 5 比较了在固定 $\text{SNR} = 20 \text{ dB}$, 导频开销 $T = 60$ 时, 不同用户数量下本文算法与其他五种算法估计所有用户信道信息的 NMSE。在用户数量较少时, 提供给本文算法的多用户共同支撑信息非最优, 可以看

出本文算法的 NMSE 与其他算法相差不大；但随着用户数量的增多，本文算法的估计性能逐渐提升且趋于稳定，并相比其他算法有明显的性能优势，所以更适合于多用户联合信道估计系统。




图 5 不同用户数量和算法下的 NMSE

Fig. 5 NMSE under different number of users and algorithms

图 6 比较了在固定 SNR=20 dB，导频开销 $T=60$ 时，不同用户数量下本文算法与其他五种算法估计所有用户信道信息所需的时间消耗。由图可知，各类算法的迭代时间随着用户数量的增多呈线性增长。本文算法的时间消耗始终保持较少，阶段 1 用户的支撑集采用共享机制，可以避免部分重复的计算步骤；在独立支撑集更新阶段，利用动态残差来准确反馈约束索引集的长度，节约了计算资源。因此在多用户联合估计的时间成本方面，本文算法表现更优。




图 6 不同用户数量和算法下的运行时间

Fig. 6 Running time under different number of users and algorithms

5 结论

本文针对多用户大规模 MIMO 系统的联合信道估计问题，设计了基于压缩感知多测向量模型的信道估计方案，旨在提升恢复性能和效率的同时降低导频开销。考虑了多用户信道矩阵间隐藏的独立稀疏性和共同稀疏性，将信道估计过程拆分成稀疏度预估计和信道重构：首先在多测向量信道模型下提出改进 PCA 分析的稀疏度估计策略，用于获取单用户信道的稀疏度，为后续重构算法提供准确的先验信息；此外提出

一种多用户联合估计算法, 该算法根据多用户信道支撑属性不同, 利用分段求解的思想来降低导频开销, 通过共享所有用户的共同支撑集, 以免去部分重复迭代步骤, 将残差的变化精确反馈至索引长度, 保证了算法具有较快的收敛速度, 同时也考虑了迭代中可能误判支撑的纠正问题, 提升了估计精度。仿真结果表明, 无论在恢复误差、导频开销还是计算效率方面, 本文提出的算法都要优于传统的压缩感知算法。

参考文献

- [1] CUI Mingyao, DAI Linglong. Channel estimation for extremely large-scale MIMO: Far-field or near-field?[J]. IEEE Transactions on Communications, 2022, 70(4): 2663-2677.
- [2] AZIZIPOUR M J, MOHAMED-POUR K. Compressed channel estimation for FDD massive MIMO systems without prior knowledge of sparse channel model[J]. IET Communications, 2019, 13(6): 657-663
- [3] WANG Yujie, QI Chenhao, LI Ping, et al. Channel estimation for wideband mmWave MIMO OFDM system exploiting block sparsity[J]. IEEE Communications Letters, 2022, 26(4): 897-901
- [4] GAO Zhen, DAI Linglong, DAI Wei, et al. Structured compressive sensing-based spatio-temporal joint channel estimation for FDD massive MIMO[J]. IEEE Transactions on Communications, 2016, 64(2): 601-617.
- [5] OZDEMIR M K, ARSLAN H. Channel estimation for wireless OFDM systems[J]. IEEE Communications Surveys & Tutorials, 2007, 9(2): 18-48.
- [6] HOYDIS J, HOEK C, WILD T, et al. Channel measurements for large antenna arrays[C]//2012 International Symposium on Wireless Communication Systems (ISWCS). Paris, France. IEEE, 2012: 811-815.
- [7] QAISAR S, BILAL R M, IQBAL W, et al. Compressive sensing: From theory to applications, a survey[J]. Journal of Communications and Networks, 2013, 15(5): 443-456.
- [8] UWAECHIA A N, MAHYUDDIN N M. A review on sparse channel estimation in OFDM system using compressed sensing[J]. IETE Technical Review, 2017, 34(5): 514-531.
- [9] FAN Jiancun, LIANG Peizhe, JIAO Zihan, et al. A compressive sensing and deep learning-based time-varying channel estimation for FDD massive MIMO systems[J]. IEEE Transactions on Vehicular Technology, 2022, 71(8): 8729-8738.
- [10] ZHENG Zhian, LIU Hao, ZHU Junjie, et al. An adaptive sparse channel estimation algorithm for OFDM systems based on distributed compressive sensing[J]. IEEE Communications Letters, 2023, 27(9): 2476-2480.
- [11] KUAI Xiaoyan, CHEN Lei, YUAN Xiaojun, et al. Structured turbo compressed sensing for downlink massive MIMO-OFDM channel estimation[J]. IEEE Transactions on Wireless Communications, 2019, 18(8): 3813-3826.
- [12] MANOJ A, KANNU A P. Channel estimation strategies for multi-user mm wave systems[J]. IEEE Transactions on Communications, 2018, 66(11): 5678-5690.
- [13] RAO Xiongbao, LAU V K N. Distributed compressive CSIT estimation and feedback for FDD multi-user massive MIMO systems[J]. IEEE Transactions on Signal Processing, 2014, 62(12): 3261-3271.
- [14] XU Wenbo, SHEN Tao, TIAN Yun, et al. Compressive channel estimation exploiting block sparsity in multi-user massive MIMO systems[C]//2017 IEEE Wireless Communications and Networking Conference (WCNC). San Francisco, CA, USA. IEEE, 2017: 1-5.
- [15] TSENG C C, WU J Y, LEE T S. Enhanced compressive downlink CSI recovery for FDD massive MIMO systems using weighted block ℓ_1 -minimization[J]. IEEE Transactions on Communications, 2016, 64(3): 1055-1067.
- [16] SEMPER S, RÖMER F, HOTZ T, et al. Sparsity order estimation from a single compressed observation vector[J]. IEEE Transactions on Signal Processing, 2018, 66(15): 3958-3971.
- [17] QIN Shaohua, YIN Juan. A Robust sparsity estimation method in compressed sensing[C]//Advances in Wireless Sensor Networks: The 8th China Conference(CWSN). Xi'an, China. Springer, 2015: 481-488.

- [18] 裴立业, 江桦, 李明. 一种基于能量的压缩感知稀疏度估计算法[J]. 电子学报, 2017, 45(2): 285-290.
PEI Liye, JIANG Hua, LI Ming. A sparsity order estimation algorithm based on measured signal's energy[J]. Acta Electronica Sinica, 2017, 45(2): 285-290.(in Chinese)
- [19] 崔伟, 于颖, 于海霞, 等. 基于 IOC-CSMP 的 OFDM 系统稀疏信道快速重构算法[J]. 通信学报, 2023, 44(2): 52-58.
CUI Wei, YU Ying, YU Haixia, et al. Sparse channel fast reconstruction algorithm for OFDM system based on IOC-CSMP[J]. Journal on Communications, 2023, 44(2): 52-58.(in Chinese)
- [20] 季策, 王金芝, 李伯群. 基于 RSAMP 算法的 OFDM 稀疏信道估计[J]. 系统工程与电子技术, 2021, 43(8): 2290-2296.
JI Ce, WANG Jinzhi, LI Boqun. OFDM sparse channel estimation based on RSAMP algorithm[J]. Systems Engineering and Electronics, 2021, 43(8): 2290-2296.(in Chinese)
- [21] GEWERS F L, FERREIRA G R, ARRUDA H F D, et al. Principal component analysis: A natural approach to data exploration[J]. ACM Computing Surveys (CSUR), 2021, 54(4): 1-34.
- [22] HABI H V, MESSER H, BRESLER Y. Learning to bound: A generative Cram -Rao bound[J]. IEEE Transactions on Signal Processing, 2023, 71: 1216-1231.
- [23] PANG Lihua, ZHANG Jin, ZHANG Yang, et al. Investigation and comparison of 5G channel models: From QuaDRiGa, NYUSIM, and MG5G perspectives[J]. Chinese Journal of Electronics, 2022, 31(1): 1-17.

作者简介



安澄全 男, 1974 年生, 黑龙江双城人。哈尔滨工程大学信息与通信工程学院副教授, 主要研究方向为无线移动通信技术、通信信号处理。

E-mail: anchengquan@hrbeu.edu.cn



杨延 男, 2001 年生, 陕西宝鸡人。哈尔滨工程大学信息与通信工程学院硕士研究生, 主要研究方向为通信信号处理、大规模 MIMO 信道估计。

E-mail: abner3410@163.com



杨茜 女, 1997 年生, 陕西岐山人。航空工业第一飞机设计研究院助理工程师, 主要研究方向为最优化算法、训练系统开发。

E-mail: qianyang201906@163.com



李俊江 男, 2000 年生, 黑龙江鹤岗人。哈尔滨工程大学信息与通信工程学院硕士研究生, 主要研究方向为移动通信技术。

E-mail: lijunjiang@hrbeu.edu.cn